

Petite histoire de la prédiction à un pas

Pierre-Olivier Amblard

22 août 2025

Avertissement. L'idée de proposer cette synthèse m'est venue en lisant le livre de Lasserre, Pauwells et Putinar [14], notamment le passage p. 29 où l'égalité entre $\exp \int \log \gamma(\lambda) d\lambda$ et la fonction de Christoffel associée à une mesure $\gamma(\lambda) d\lambda$ sur le cercle unité est dévoilée. Ce livre n'aborde pas le problème de la prédiction des processus stationnaires, mais j'ai reconnu avec stupeur dans cette égalité l'erreur quadratique moyenne asymptotique du prédicteur linéaire à un pas d'un signal stationnaire de densité spectrale $\gamma(\lambda)$. J'ai immédiatement fouillé la littérature pour rapidement m'apercevoir que quelques glorieux anciens, dont Thomas Kailath [10], avaient observé et étudié avec bonheur les liens entre prédiction linéaire et polynômes orthogonaux sur le cercle unité.

Ce texte ne comporte donc aucun résultat nouveau, et les analogies qui y sont présentées ont été observées par d'autres par le passé (dont [4, 10], avec de nombreuses sources historiques détaillées en particulier dans [17, 26, 28], voir aussi [16] pour des liens avec les espaces de Hardy), et sont peut-être connues par de nombreux de mes collègues. Mais les liens profonds entre prédiction linéaire et polynômes orthogonaux sont si beaux que je propose ici d'en faire une présentation personnelle, en rappelant quelques éléments historiques. Elle est limitée pour le moment au cas du temps discret. Des extensions au cas du temps continu existent mais compliquent les développements.

Ce texte détaille et étend le papier soumis en mars 2025 à la conférence GRETSI 2025 [3]. Il est en cours de développement, sujet à modifications, probablement parsemé de coquilles, et incomplet. Si par hasard des lecteurs intéressés veulent me faire des retours, je les écouterai avec intérêt.

Déroulé. Ce texte mélange des aspects historiques et les développements théoriques nécessaires au développement de la théorie de la prédiction linéaire des processus aléatoires stationnaires. Il a également pour but de montrer les liens profonds entre cette théorie et la théorie des polynômes orthogonaux sur le cercle unité.

Mais chemin faisant, des pans très différents des mathématiques et de leurs applications seront rencontrés. Toute l'histoire développée ici repose sur l'analyse de Fourier, le comportement asymptotique des matrices Toeplitz, l'analyse de la fonction complexe de la variable complexe, ...; Des disciplines différentes seront également évoquées, puisque cette histoire de la prédiction a ses racines en physique expérimentale, en statistique, en analyse mathématique, en ingénierie, ...

Je n'adopterai pas une progression linéaire dans la présentation qui vient.

Le texte débutera par l'examen d'aspects historiques sur l'analyse de Fourier utilisée au début du XX^{ème} siècle pour la recherche de périodicités dans des séries temporelles essentiellement géophysiques. Cette analyse montrera comment elle a conduit Yule à introduire le modèle auto-régressif en 1928, puis comment elle a débouché sur la décomposition de Wold, décomposition fondamentale. Suivra une présentation de la prédiction linéaire des séries stationnaires. Le cadre théorique adopté est le cadre très général de Kolmogorov [13] concernant

les séries stationnaires dans un espace de Hilbert. Après avoir présenté les développements effectués par des mathématiciens et des ingénieurs du signal, nous reviendrons en arrière pour nous intéresser aux matrices Toeplitz, aux polynômes orthogonaux sur le cercle unité et finirons par faire monter la mayonnaise.

Le programme actuel (non entièrement complété) est le suivant :

Table des matières

1 A la recherche des périodicité cachées.	2
2 Séries stationnaires.	5
3 Décomposition de Wold.	6
4 Prédiction linéaire à un pas des séries stationnaires.	7
5 Prédiction et filtrage de Wiener à temps discret.	7
6 Un premier lien avec les déterminants de matrices Toeplitz.	9
7 Polynômes orthogonaux sur $\partial\mathbb{D}$, le cercle unité.	11
8 Lien entre les OPUC et la prédiction linéaire	12
9 Quelques conséquences diverses et variées	13
10 Filtre de Kalman	14
11 Extension multivariée.	14
12 Prédiction et causalité (de Wiener-Granger)	17
13 Appendice : MOPUC.	19

1 A la recherche des périodicité cachées.

Dans une séries d'articles fondamentaux [22, 23, 24, 25], Sir A. Schuster au tournant du XXème siècle jette les bases de l'analyse spectrale de Fourier. Il introduit la notion de périodographe et de périodogramme et étudie sur des bases probabilistes la présence ou non de périodicité dans une série temporelle. Dans [22], cette approche lui permet de réfuter un résultat liant la fréquence des tremblements de terre aux effets de marée.

L'introduction de [23] est limpide. L'auteur y distingue les périodicités évidentes ("obvious") comme par exemple la récurrence de 11 ans du maximum solaire (mesurée par le nombre de taches solaires) des périodicités cachées ("hidden") derrière des fluctuations des variables mesurées. Il prend l'exemple de l'influence lunaire sur la variation journalière des forces magnétiques. Un autre exemple plus polémique à l'époque est celui de l'influence de la période de rotation du soleil sur différentes mesures terrestres. Il justifie ainsi le besoin d'avoir recours à la théorie des probabilités pour :

[to] be able to assign a definite number for the probability that the effects found by means of the usual methods are real, and not due to accident.

La méthode usuelle qu'il décrit est celle de la moyenne synchrone. Face à une suite d'évènements mesurés régulièrement, pour vérifier la présence d'une période de répétition p , il s'agit de sommer en phase des morceaux de longueur p de la suite mesurée, puis de décomposer en série de Fourier cette somme S . Schuster adopte une approche fondée sur un test statistique. Il définit la grandeur ρ somme étant le rapport de la puissance de la première harmonique à la valeur moyenne de S . Il pose alors la question :

What is the probability that ρ should lie between any two assigned values ρ_1 and ρ_2 , on the supposition that the events are distributed quite at random?

Il cherche ici la loi sous l'hypothèse nulle qu'une série est non périodique. Pour trouver cette probabilité, il utilise une première fois une analogie optique et le résultat de Lord Rayleigh [21] sur la loi du module de la somme de vecteurs gaussiens. Il caractérise son approche par la probabilité de fausse alarme. Dans son article suivant [24], Schuster est un peu plus explicite. Il précise que pour la classe de fonctions à laquelle il s'intéresse, le module carré de l'amplitude de la première harmonique calculée entre deux temps τ et $\tau + nT$ fluctue autour d'une valeur moyenne en fonction de τ . Il définit S^2 comme cette moyenne et nomme "périodographe" le graphe de la fonction $S^2(T)$. Le périodogramme est l'intégrale du périodographe ! Schuster fait implicitement ici une hypothèse de stationnarité. Il fait ensuite une hypothèse d'indépendance pour introduire ce que l'on appelle aujourd'hui le périodogramme moyenné : confronté à une série qui fluctue, il découpe l'intervalle de longueur nT en sous-intervalles de longueurs n/mT , calcule S^2 sur chacun de ces sous-intervalles et opère une moyenne arithmétique. Il calcule explicitement S^2 pour une série sinusoïdale et effectue une deuxième analogie optique, puisqu'il montre que le résultat est précisément égal à la puissance lumineuse obtenue par un réseau de diffraction. Ces deux calculs lui permettent de conclure qu'une périodicité noyée dans un bruit peut être détectée par le périodographe, à condition que la durée d'observation T soit suffisamment longue. En effet, S^2 est indépendant de T pour une série périodique si T est un multiple de la période cherchée, alors que S^2 décroît comme $1/T$ si un bruit seul est analysé. Schuster donne à nouveau des résultats d'intervalle de confiance pour S^2 sous l'hypothèse nulle en utilisant les travaux de Rayleigh et en les généralisant à la somme d'un nombre supérieur à deux de vecteurs gaussiens. L'approche de Schuster est ensuite généralisée en 1929 par Slutsky [29]. L'hypothèse d'échantillons indépendants est levée et la notion de signal stationnaire au deuxième ordre clairement invoquée, et ce avant les premiers travaux de Khintchine.

En 1925 Walker [31] suggère d'utiliser également le corrélogramme (*a priori* indépendamment proposé par Alter en 1927 [2]). Il remarque effectivement que la corrélation (empirique) entre deux échantillons séparés de p intervalles de temps doit se comporter périodiquement lorsque p varie. Cette suggestion est faite pour lutter contre d'éventuelles variations de phase de l'oscillation au cours du temps. Sous cette hypothèse, la moyenne synchrone n'est plus synchrone, et la méthode de Schuster échoue. Le corrélogramme permet de remédier à ce problème. Il est à noter que Walker aurait dû remarquer que le périodogramme moyenné introduit par Schuster (calcul des séries de Fourier bloc par bloc et prise du module carré avant moyennage dans l'analyse des séries purement aléatoires) remédie également au problème de cette phase.

La corrélation est utilisée depuis longtemps en 1925. Toutefois, confrontés à des séries temporelles, les statisticiens utilisent le coefficient de corrélation instantané, utilisation qui conduit à des résultats paradoxaux dans l'analyse de certaines séries temporelles. Pour démythifier ces problèmes et introduire la fonction de corrélation, Yule en 1926 discute des problèmes liés à la présence de forme déterministes sous-jacentes aux fluctuations (tendances) et suggérant aussi des corrélations entre instants différents pour les fluctuations elles-mêmes [38]. Pour justifier le propos, il étudie le cas intéressant de la corrélation entre la mortalité infantile (proportion pour 1000 naissances) en Angleterre et Pays de Galles entre 1866 et 1911, et le taux de mariages dans l'église anglicane (proportion pour 1000 mariages) sur la même période en Angleterre. Il

évalue à 0.9512 cette corrélation (!), mais se garde bien évidemment de tirer des conclusions. Il discute d'éventuelles causes communes, mais évacue évidemment rapidement cette hypothèse au profit de la structure même des séries, composées de tendances déterministes et de fluctuations aléatoires superposées. Dans sa discussion sur les aléas, Yule fait implicitement l'hypothèse de stationnarité. Durant cette décennie, les idées pour contrer ces corrélations sans sens, des approches fondées sur les incréments sont déjà évoquées (par exemple Yule en 1921 [37] qui permettent d'éliminer des tendances.

Le problème déjà évoqué de fluctuations de phase et de fréquence dans les séries est le principale frein à l'utilisation du périodogramme de Schuster. Si la résolution dépend bien sûr de la largeur des blocs moyennés, Yule note aussi que dans certaines séries, l'élargissement de raies spectrales peut être inhérente à la physique, et que les perturbations aléatoires ne sont pas nécessairement instantanées. La discussion de Yule [39] est lumineuse :

If we take a curve representing a simple harmonic function of the time, and superpose on the ordinates small random errors, the only effect is to make the graph somewhat irregular, leaving the suggestion of periodicity still quite clear to the eye.

Yule parle ici de bruit additif et mentionne rapidement le fait que la méthode du périodogramme est efficace pour déterminer la fréquence, à condition toutefois d'observer suffisamment longtemps si le bruit est fort. Il ajoute :

But by improvement of apparatus and automatic methods of recording, let us say, errors of observation are practically eliminated. The recording apparatus is left to itself, and unfortunately boys get into the room and start pelting the pendulum with peas, sometimes from one side and sometimes from the other. The motion is now affected, not by superposed fluctuations but by true disturbances, and effect on the graph will be of an entirely different kind. The graph will remain surprisingly smooth, but amplitude and phase will vary continually.

Les garçons¹ entrant dans la salle perturbent non pas l'instrument de mesure mais le processus physique à l'étude (un pendule), générant des perturbations aléatoires continues à la fois de l'amplitude et de la phase des grandeurs mesurées. Partant alors de l'équation aux différences gérant une harmonique pure $x_t = 2 \cos(\theta)x_{t-1} - x_{t-2}$, Yule introduit les « true disturbances » dans l'équation à chaque instant $x_t = 2 \cos(\theta)x_{t-1} - x_{t-2} + \varepsilon_t$, écrivant un modèle AR pour la première fois. Il montre ensuite comment estimer le paramètre à l'aide des corrélations dans le cas d'une période (AR(2)) et de deux (AR(4)), mais n'écrit pas l'équation qui porte son nom. En 1931, Sir Walker généralise à tout ordre l'équation du modèle AR et illustre comment en calculer les coefficients, en montrant que les corrélations suivent la même équation aux différences, mais sans le terme de perturbation. Bref, il démontre dans [32] l'équation de Yule-Walker.

Pour terminer ce paragraphe et faire le lien avec le suivant, il faut décrire la théorisation de l'approche de Schuster fait par N. Wiener en 1930 dans son papier fondamental "Generalized harmonic analysis" [34]. Pour justifier le besoin de généraliser l'analyse harmonique, Wiener se réfère aux développements récents à l'époque des fonctions presque-periodiques mais aussi aux travaux de Schuster cités plus haut, surtout dans le parallèle fait par Schuster avec la théorie de la lumière blanche en optique. Wiener explique que les formules utilisées par Schuster, par exemple $T^{-1} \int_{t_1}^{t_1+T} y(t) \cos(xt) dt$ comme indiqué plus haut, sont en fait des avatars d'un opérateur de moyenne plus général dans lequel T tend vers l'infini. Par ailleurs Wiener remarque que le périodogramme de Schuster s'intègre son approche généralisée, approche dédiée à l'analyse harmonique de fonctions y qui ne sont pas d'énergie finie, mais dans notre vision moderne, qui sont de puissance moyenne finie, soit

$$\lim_{T \rightarrow +\infty} \frac{1}{T} \int_{-T/2}^{T/2} |y(t)|^2 dt < +\infty$$

1. N'oublions pas que Yule écrit en 1927...

dont les fonctions presque périodiques font partie. Pour montrer l'importance de son approche, Wiener considère une fonction presque périodique $y(t) = \sum_{n=1}^N a_n \exp(2i\pi\lambda_n t)$. La corrélation de y calculée à l'aide de l'opérateur de moyenne $\lim_{T \rightarrow +\infty} \frac{1}{T} \int_{-T/2}^{T/2}$ est

$$\Gamma_{yy}(x) = \lim_{T \rightarrow +\infty} \frac{1}{T} \int_{-T/2}^{T/2} y(t+x) \overline{y(t)} dt = \sum_{n=1}^N |a_n|^2 \exp(2i\pi\lambda_n x)$$

Dans l'approche de Schuster, le périodogramme S^2 à la période $1/\lambda_k$ sera donc en théorie

$$S^2(\lambda_k) = \lim_{T \rightarrow +\infty} \frac{1}{T} \int_{-T/2}^{T/2} \Gamma_{yy}(x) \exp(-2i\pi\lambda_k x) dx = |a_k|^2$$

Mais en pratique, la limite ne peut être évaluée, et si elle ne l'est pas, le périodogramme de Schuster à la fréquence λ_k

$$\begin{aligned} S^2(\lambda_k) &= \frac{1}{T} \int_{-T/2}^{T/2} \left\{ \frac{1}{T} \int_{-T/2}^{T/2} y(t+x) \overline{y(t)} dt \right\} e^{-2i\pi\lambda_k x} dx \\ &= |a_k|^2 + \sum_{m \neq k} a_k \overline{a_m} \frac{\sin((\lambda_k - \lambda_m)T/2)}{(\lambda_k - \lambda_m)T/2} \end{aligned}$$

peut prendre des valeurs négatives !

Wiener définit alors la fonction tronquée $y_T(t) = y(t) \mathbf{1}_{|t| < T/2}$ puis introduit correctement le périodogramme de Schuster comme étant

$$I_T(\nu) = \frac{1}{T^2} \left| \int_{-T/2}^{T/2} y_T(t) e^{-2i\pi\nu t} dt \right|^2$$

dont on montre qu'il est la transformée de Fourier de la fonction de corrélation de la fonction tronquée, soit

$$I_T(\nu) = \frac{1}{T} \int_{-\infty}^{+\infty} \left\{ \frac{1}{T} \int_{-\infty}^{+\infty} y_T(t+x) \overline{y_T(t)} dt \right\} e^{-2i\pi\nu x} dx$$

expression assurée d'être positive. Evidemment, pour développer la théorie de l'analyse harmonique généralisée, Wiener utilise implicitement la notion de stationnarité. Notons toutefois qu'il justifie la forme de la corrélation en examinant l'invariance des produits scalaires considérés sous l'effet d'actions d'un groupe unitaire à un paramètre.

Nous pouvons nous tourner maintenant vers la théorie géométrique des signaux stationnaires, développée par Kolmogorov en 1941.

2 Séries stationnaires.

L'étude des signaux stationnaires trouvent ses racines dans l'analyse harmonique des signaux présentant des périodicités cachées, comme illustré précédemment. Les travaux fondamentaux débutent avec Khintchine en 1932 et 1934 [11, 12]. Le papier de 1934 est particulièrement important. Il présente clairement la notion de stationnarité, puis se limite à l'ordre 2 et réalise l'analyse harmonique en montrant l'existence d'une mesure spectrale comme transformée de Fourier de la fonction de corrélation. Il utilise pour cela le théorème de Bochner.

Kolmogorov et les espaces de Hilbert. Dans [13], Kolmogorov développe la théorie des séries stationnaires à l'aide de la théorie des espaces de Hilbert. Soit $\mathcal{H}$ un tel espace dont les vecteurs

sont les signaux d'intérêt. Deux séries x_t et y_t de $\mathcal{H}$ sont conjointement stationnaires si le produit scalaire $\langle \cdot | \cdot \rangle_{\mathcal{H}}$ de $\mathcal{H}$ entre x_t et y_{t+k} est indépendant de $t \in \mathbb{Z}$. On note $\mathcal{H}_{xy}$ le plus petit sous-espace vectoriel fermé de $\mathcal{H}$ contenant l'ensemble des éléments x_t et y_t . On note également $\mathcal{H}_x(t)$ le plus petit sous-espace vectoriel fermé de $\mathcal{H}$ généré par le passé $\{x_s\}_{s \leq t}$.

Soit x_t une série stationnaire ; Kolmogorov montre en utilisant la théorie des représentations spectrales des opérateurs unitaires qu'il existe une fonction positive, non décroissante, continue à droite $\Gamma_x : [-1/2, 1/2] \rightarrow \mathbb{C}$ telle que Γ_x définisse un produit scalaire entre deux fonctions f et g de $[-1/2, 1/2]$ dans $\mathbb{C}$

$$\langle f | g \rangle_{\Gamma_x} = \int_{-1/2}^{1/2} f(\lambda) \bar{g}(\lambda) d\Gamma_x(\lambda)$$

L'ensemble de fonctions pour lequel ce produit scalaire a un sens est l'espace $L^2(\Gamma_x)$ des fonctions de $[-1/2, 1/2]$ dans $\mathbb{C}$ de module carré sommable contre Γ_x . Il faut noter la puissance du formalisme développé par Kolmogorov, puisqu'il inclut la théorie de processus stochastiques stationnaires aussi bien que la théorie des signaux déterministes d'énergie finie ou encore de puissance moyenne finie.

3 Décomposition de Wold.

Travail précédent la théorie de Kolmogorov, le livre (sa thèse) de Wold n'en est probablement pas moins une des inspirations pour [13], puisque la décomposition de Wold [36] est citée par Kolmogorov dès la première page de son article, et est démontrée avec les moyens géométriques des espaces de Hilbert dans son paragraphe 7. Le livre de Wold est très intéressant à lire. Il propose dans le premier chapitre un tour d'horizon sur l'état de l'art au milieu des années 30 de l'analyse des séries temporelles. A l'époque, la théorie des processus stochastiques est naissante, suite à la formalisation moderne de la théorie des probabilités par Kolmogorov (1931), et les travaux de Khintchine (1932-34) et encore de Kolmogorov (1933). Si Khintchine a déjà développé la théorie générale pour des signaux discrets, il revient à Wold d'avoir développé des modèles généraux pour les séries aléatoires. Pour cela, il s'inspire de nombreux travaux de la toute fin du XIXème siècle et des trente premières années du vingtième sur la recherche de *périodicités cachées* dans les séries temporelles. Les noms importants importants ici sont H. Burkhard, A. Schuster, K. Stumpff, E.T. Whittaker et de nombreux autres travaillant à la recherche de périodicités dans des séries géophysiques ou (déjà) financières. Si les approches fonctionnelles reposant sur les séries de Fourier sont déjà largement utilisées, quelques auteurs travaillent sur des équations aux différences. Beaucoup d'approches tentent de représenter et expliquer des raies spectrales d'épaisseur plus large que la résolution donnée par le déjà célèbre périodogramme. Il faut attendre Yule [39], puis Walker [32], pour que des idées d'aléas soient introduites, comme développé précédemment.

Wold reprend ces travaux à vocations pratiques pour faire une théorie complète des processus stationnaires à temps discret. Son livre culmine dans la présentation de la décomposition de Wold qui représentent tout processus de carré sommable comme la somme d'un processus singulier et d'un processus à moyenne ajustée (mobile) d'ordre infini.

Un signal est dit *singulier* s'il peut s'écrire à chaque instant comme combinaison linéaire de son passé. Autrement dit, x est singulier si $\bigcap_{t \in \mathbb{Z}} \mathcal{H}_x(t) = \{0\}$. Pour un signal stationnaire x_t quelconque de $\mathcal{H}$, la projection orthogonale s_t^x de x sur $\bigcap_{t \in \mathbb{Z}} \mathcal{H}_x(t)$ représente la partie singulière de x . Si s_t^x est la projection orthogonale de x_t sur $\mathcal{H}_x(t-1)$, alors x_t s'écrit de manière unique sous la forme $x_t = s_t^x + \sum_{n \geq 1} c_n^x \varepsilon_{t-n}^x$, où la série $\{\varepsilon_s^x\}_{s \leq t}$ est un système complet et orthonormal de $\mathcal{H}_x(t) \setminus \bigcap_{t \in \mathbb{Z}} \mathcal{H}_x(t)$. Cet argument constitue la décomposition de Wold de x_t en une partie singulière s_t et une partie régulière donnée par une moyenne mobile causale d'une

suite stationnaire d'échantillons indépendants [36, th. 7]. Un signal est alors dit régulier si sa partie singulière est nulle. Dans ce cas la densité spectrale de puissance est strictement positive, et ε_t peut s'écrire comme combinaison linéaire de $\{\varepsilon_s^x\}_{s \leq t}$, autrement dit, x_t peut s'écrire sous forme d'une récursion d'ordre infini attaqué par l'innovation ε_t (modèle AR d'ordre ∞). Cet argument permet à Wold de justifier l'existence de solutions à une équation aux différences d'ordre fini avec une entrée aléatoire, et donc d'introduire rigoureusement la notion de modèle AR d'ordre fini. Par ailleurs, si l'on écrit explicitement $x_t = \sum_{n>0} b_n x_{t-n} + \varepsilon_t$, le lien avec la prédiction linéaire devient évident.

4 Prédiction linéaire à un pas des séries stationnaires.

Soit x_t une série stationnaire de $\mathcal{H}$. La prédiction linéaire s'intéresse à représenter x_t comme une combinaison linéaire de ses échantillons passés, soit $\hat{x}_t^n = \sum_{i=1}^n a_i^n x_{t-i}$. Les paramètres sont choisis de sorte à minimiser l'erreur quadratique moyenne mesurée à l'aide du produit scalaire $\langle \cdot | \cdot \rangle_{\mathcal{H}}$, et le programme à résoudre est

$$\sigma_n^2(t) = \inf_{a^n} \|x_t - \hat{x}_t^n\|_{\mathcal{H}}^2 = \min_{a^n} \|x_t - \sum_{i=1}^n a_i^n x_{t-i}\|_{\mathcal{H}}^2$$

L'utilisation de la géométrie des espaces de Hilbert permet de trouver l'argument $\hat{x}_0^n$ optimal en utilisant le théorème de la projection orthogonale. Si $\mathcal{H}_x(1:n)$ est le plus petit sous-espace vectoriel de $\mathcal{H}$ contenant les suites $x_{t-1}, \dots, x_{t-n}$, alors $\hat{x}_0^n$ satisfait

$$\langle x_t - \hat{x}_0^n | z_t \rangle_{\mathcal{H}} = 0, \quad \forall z_t \in \mathcal{H}_x(1:n)$$

qui conduit à l'équation de Yule-Walker [32]

$$T_n a^n = \begin{pmatrix} c_0 & c_1 & \cdots & c_{n-1} \\ c_{-1} & c_0 & \ddots & \vdots \\ \vdots & & \ddots & c_1 \\ c_{1-n} & \cdots & c_{-1} & c_0 \end{pmatrix} a^n = \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} = R_n \quad (1)$$

où $c_k = \langle x_t | x_{t-k} \rangle_{\mathcal{H}}$. L'erreur quadratique minimale obtenue est indépendante du temps et s'écrit $\sigma_n^2 = c_0 - R_n^T T_n^{-1} R_n$. Cette solution est la prédiction à un pas à passé fini, puisque le prédicteur n'utilise qu'un nombre fini n des échantillons. Dans le cas où ce nombre n tend vers l'infini, la prédiction est dite à passé infini. Dans ce cas $\sigma_\infty^2 = \lim_{n \rightarrow +\infty} \sigma_n^2$ représente l'erreur quadratique de prédiction à un pas à passé infini. On infère d'emblée que σ_∞^2 correspond à la puissance de l'innovation ε_t dans la représentation de Wold d'un signal régulier. L'évaluation de σ_∞^2 n'est pas aisée. Nous donnons deux preuves de nature différente, la première ayant recours à la théorie du filtrage de Wiener causal à temps discret, appliquée au cas particulier de la prédiction, et reposant sur la théorie de la factorisation spectrale forte. Cette route est suivie par exemple dans [5, 19]. La deuxième utilise des résultats asymptotiques sur les déterminants de matrices circulantes et des notions d'équivalence de matrices circulantes et Toeplitz [9].

5 Prédiction et filtrage de Wiener à temps discret.

Le filtrage de Wiener consiste pour estimer un signal s_t à partir d'une observation x_t à utiliser une combinaison linéaire des échantillons de x . Si l'on suppose avoir observé l'intégralité de x_t , l'estimateur de s s'écrit

$$\hat{s}_t = \sum_{k \in \mathbb{Z}} a_k x_{t-k}$$

et est obtenu en minimisant l'erreur quadratique moyenne $\sigma_s^2(t) = \inf_a \|s_t - \hat{s}_t\|_{\mathcal{H}}^2$. L'utilisation de la géométrie dans les espaces de Hilbert conduit alors à l'équation de Wiener-Hopf pour la suite a

$$\Gamma_k^{sx} = \sum_{l \in \mathbb{Z}} a_l \Gamma_{k-l}^{xx}$$

où $\Gamma_k^{xy} = \langle x_t | y_{t-k} \rangle_{\mathcal{H}}$ est la fonction de covariance entre les séries conjointement stationnaires x et y , qui peut, si aucune contrainte n'est imposée à a , être résolue en passant dans le domaine de Fourier sur le cercle unité, ou en utilisant la transformée en z .

Une parenthèse : l'équation de Wiener-Hopf.

Retour à la prédiction. La nécessité d'obtenir des implantations physiques de l'estimateur de Wiener oblige à considérer des solutions causales à l'équation de Wiener-Hopf. En particulier, le problème de la prédiction linéaire impose de n'utiliser que les échantillons passés de x_t pour estimer x_{t+1} . La contrainte de causalité impose de rechercher la série a dans l'espace des séries causales, à savoir l'ensemble des séries a_k nulles pour les temps négatifs $k < 0$, donnée par la solution de

$$\Gamma_k^{sx} = \sum_{l \geq 0} a_l \Gamma_{k-l}^{xx}$$

L'approche classique pour résoudre le problème consiste à remarquer que si x est un bruit blanc de puissance unité, l'équation précédente est particulièrement simple puisqu'on obtient directement $a_k^* = \Gamma_k^{sx}$ pour $k \geq 0$ et $a_k^* = 0$ pour $k < 0$. a_k^* est donc la partie causale de Γ_k^{sx} , dont la transformée en z sera notée $\gamma_{sx}^+(z)$. Pour résoudre le problème général, il convient alors de réaliser de réaliser un blanchiment *causal*, *causalement inversible* et *normeur* de x , puis d'estimer s à partir du signal blanchi : la cascade de ces deux filtres résoud l'équation de Wiener-Hopf causale. Le filtre blanchisseur normeur, causal et causalement inversible est obtenu en réalisant la factorisation forte de la densité spectrale de puissance $\gamma_{xx}(z) = H^+(z)\overline{H^+}(1/\bar{z})$, H^+ étant un filtre causal, d'inverse causal. Le filtre a^* optimal a alors pour gain complexe

$$A^*(z) = \frac{1}{H^+(z)} G^+(z) \text{ où } G(z) = \frac{\gamma_{sx}(z)}{H^+(1/\bar{z})}$$

et l'erreur quadratique moyenne d'estimation minimale étant donnée par

$$\sigma_{s^*}^2 = \Gamma_0^{ss} - \sum_{k \geq 0} h_k^* \Gamma_k^{sx} = \Gamma_0^{ss} - \frac{1}{2\pi} \oint G^+(z) \overline{G^+}(1/\bar{z}) \frac{dz}{z}$$

La spécialisation au cas de la prédiction linéaire conduit alors au résultat cherché.

Dans ce cas particulier, $s_t = x_{t+1}$ et donc $\gamma_{sx}(z) = z\gamma_{xx}(z)$ qui conduit à $A^*(z) = (zH^+(z))^+ / H^+(z)$. Écrivons $H^+(z) = h_0 + \sum_{k>0} h_k z^{-k} = h_0 + K(z)$. Alors $A^*(z) = zK(z)/(h_0 + K(z))$. En l'espèce, $A^*(z)$ permet d'estimer x_{t+1} à partir de son passé, et donc $z^{-1}A^*(z)$ permet d'estimer x_t à partir de son passé. L'erreur de prédiction optimale $x_t - \hat{x}_t$ s'obtient alors à partir du filtrage de x_t par le filtre de gain complexe $1 - z^{-1}A^*(z)$, c'est-à-dire par le filtre de gain $h_0/H^+(z)$: ce filtre est un filtre blanchisseur. Son signal de sortie est l'erreur de prédiction à un pas à passé infini qui est donc une série blanche, par définition de puissance σ_∞^2 donc égale à $|h_0|^2$.

Si $\log \gamma_{xx}(\lambda) > -\infty$ alors $\log |H^+(\lambda)| > -\infty$ également. H^+ étant causal et causalement inversible, tous ses pôles et zéros sont à l'intérieur du cercle unité strictement. Il en est alors de même pour $\log H^+$, qui est donc le gain complexe d'une série causale, et peut s'écrire

$$\log H^+(z) = \ell_0 + \sum_{k>0} \ell_k z^{-k}$$

et $\ell_0 = \log |h_0|$. Pour $z \in \partial\mathbb{D}$ cette dernière expression est une série de Fourier et donc

$$\ell(0) = \int_{-1/2}^{1/2} \log(H^+(\lambda)) d\lambda$$

La réalité du filtre impose $H^+(\lambda) = \overline{H^+(\lambda)}$ et donc la phase de H^+ est impaire sur le cercle unité. Donc

$$\ell(0) = \log |h_0| = \int_{-1/2}^{1/2} \log(|H^+(\lambda)|) d\lambda$$

Finalement, on obtient

$$\sigma_\infty^2 = |h_0|^2 = \exp(2\ell(0)) = \exp \int_{-1/2}^{1/2} \log \gamma_{xx}(\lambda) d\lambda$$

Si $\log \gamma_{xx}(\lambda) = -\infty$ alors $\sigma_\infty^2 = 0$ qui correspond à une estimation singulière.

6 Un premier lien avec les déterminants de matrices Toeplitz.

L'erreur quadratique de prédiction à un pas est $\sigma_n^2 = c_0 - R_n^\top T_n^{-1} R_n$ où T_n et R_n , respectivement sont définis par l'équation (1). Comme $c_i = c_{-i}$ dans le cas réel, la matrice T_n est compartimentée selon

$$T_n = \left(\begin{array}{c|c} c_0 & R_{n-1}^\top \\ \hline R_{n-1} & T_{n-1} \end{array} \right)$$

de sorte que

$$\text{Det } T_n = \text{Det } (c_0 - R_{n-1}^\top T_{n-1}^{-1} R_{n-1}) \text{Det } T_{n-1}$$

qui montre que

$$\sigma_n^2 = \frac{\text{Det } T_{n+1}}{\text{Det } T_n}$$

Par ailleurs, la suite σ_n^2 est décroissante. Ce fait doit être vrai puisque la prédiction à un pas ne peut être que de meilleure de qualité quand la taille du passé augmente. La décroissance peut également se montrer en calculant l'incrément $\sigma_n^2 - \sigma_{n-1}^2$ explicitement

$$\begin{aligned} \sigma_n^2 - \sigma_{n-1}^2 &= R_{n-1}^\top T_{n-1}^{-1} R_{n-1} - R_n^\top T_n^{-1} R_n \\ &= -\frac{(c_n - R_{n-1}^\top T_{n-1}^{-1} R_{n-1})^2}{c_0 - R_{n-1}^\top T_{n-1}^{-1} R_{n-1}} \leq 0. \end{aligned}$$

Le logarithme de σ_n^2 est donc également une suite décroissante et donc la réciproque du Lemme de Césaro indique que $\log \sigma_n^2$ et $(n+1)^{-1} \sum_n \log \sigma_n^2$ ont même limite (éventuellement $-\infty$). Or, la somme des log est ici une somme télescopique et $(n+1)^{-1} \sum_n \log \sigma_n^2 = (n+1)^{-1} \log \text{Det } T_{n+1} - (n+1)^{-1} \log \text{Det } T_0$ dont la limite est la même que celle de $(n+1)^{-1} \log \text{Det } T_{n+1}$, soit l'exponentielle de la limite de $(\text{Det } T_n)^{1/n}$.

Dans un rapport ancien (première édition en 1971) publié en 2006, R. Gray propose une analyse mathématique simple pour l'étude des grandes matrices Toeplitz [9]. Il s'agit d'approcher une matrice Toeplitz par une matrice circulante, de sorte qu'elles soient asymptotiquement équivalentes (la norme de leur différence tend vers 0). Dans ce cas, les spectres de valeurs propres

sont équivalents en un certain sens. Par ailleurs, le comportement asymptotique des matrices circulantes est assez aisée à étudier, puisque ces matrices diagonalisent dans la base de Fourier, avec comme valeurs propres les coefficients de Fourier. Ainsi, si $C_{kj} = c_{(j-k) \bmod n}$ où $c_k = \int_{-1/2}^{1/2} f(\lambda) e^{2i\pi k\lambda} d\lambda$ est une séquence de corrélation, alors

$$\lim_{n \rightarrow +\infty} \log(\text{Det } C_n)^{1/n} = \lim_{n \rightarrow +\infty} \frac{1}{n} \sum_{m=0}^{n-1} \log f\left(\frac{m}{n}\right) = \int_{-1/2}^{1/2} \log f(\lambda) d\lambda$$

L'équivalence asymptotique de la matrice T_n et de sa sœur circulante C_n permet alors de montrer pour $f = \gamma_{xx}$ que

$$\sigma_\infty^2 = \lim_{n \rightarrow +\infty} (\text{Det } T_n)^{1/n} = \exp \int_{-1/2}^{1/2} \log \gamma_{xx}(\lambda) d\lambda$$

Espaces de Hardy. Les espaces de Hardy sont précisément les espaces fonctionnels pour lesquels la transformée de Fourier d'une fonction est nulle pour les fréquences négatives. Chercher une solution causale au filtrage de Wiener revient donc à chercher un filtre dont le gain complexe appartient à un espace de Hardy sur le cercle unité,

$$H(\partial\mathbb{D}) = \{g : \partial\mathbb{D} \rightarrow \mathbb{C} / \int_{-1/2}^{1/2} g(\lambda) e^{2i\pi\lambda k} d\lambda = 0, \quad \forall k < 0\}$$

$$\sigma_\infty^2 = \exp \int_{-1/2}^{1/2} \log \gamma(\lambda) d\lambda$$

Notons que, comme $\log \gamma(\lambda) \leq \gamma(\lambda)$, $-\infty \leq \int_{-1/2}^{1/2} \log \gamma(\lambda) d\lambda < +\infty$, et donc que $\sigma_\infty^2 \geq 0$. Le cas $\sigma_\infty^2 = 0$ correspond à une série singulière.

Corrélations partielles, algorithme de Levinson-Durbin. Publié en 1947, l'algorithme de Levinson vise à implanter pratiquement le filtre de Wiener, et interroge l'importance de la prise en compte de la taille du filtre dans la qualité d'estimation du filtre, débouchant sur une structure réursive naturelle. Levinson mentionne dans l'introduction l'influence sur son travail de deux rapports confidentiels (Phillips&Weiss; Blackman,Bode&Shannon) sur le lissage et la prédiction pour le guidage des engins de tirs. L'argument fondamental utilisé dans la construction de l'algorithme est l'invariance de la fonction de corrélation sous l'action du renversement du temps, propriété due à la stationnarité des séries. L'algorithme est le suivant [6, 19]

$$\begin{aligned} a_n^n &= (c_n - \sum_{j=1}^{n-1} a_j^{n-1} c_{n-j}) (\sigma_{n-1}^2)^{-1} \\ a_i^n &= a_i^{n-1} - a_n^n a_{n-i}^{n-1}, \quad \forall i = 1, \dots, n-1 \\ \sigma_n^2 &= \sigma_{n-1}^2 (1 - (a_n^n)^2) \end{aligned}$$

initialisé avec $a_1^1 = c_1/c_0$, $\sigma_0^2 = c_0$. Il est intéressant de noter que a_n^n est la *covariance partielle* entre deux échantillons du signal séparés de $n-1$ autres. Autrement dit, c'est la covariance résiduelle entre ces deux échantillons après soustraction de leur estimation linéaire optimale respective à partir des échantillons du milieu. De plus, si n tend vers l'infini, nous obtenons une deuxième expression pour l'erreur quadratique minimale de prédiction

$$\sigma_\infty^2 = c_0 \prod_{j=1}^{\infty} (1 - (a_j^j)^2) = \exp \int_{-1/2}^{1/2} \log \gamma(\lambda) d\lambda$$

7 Polynômes orthogonaux sur $\partial\mathbb{D}$, le cercle unité.

Les deux tomes [26, 27] de *Orthogonal Polynomial on the Unit Circle* (OPUC) de Barry Simon constituent à ce jour la référence ultime sur le sujet, et beaucoup de ce qui suit s'en inspire.

Récursion de Szegő. Soit Γ une mesure sur le cercle unité ou de manière équivalente sur $[-1/2, 1/2]$. On considère l'espace $L^2(\Gamma)$ des fonctions de carré sommable sur cet intervalle contre la mesure Γ , et le produit scalaire usuel associé $\langle f|g \rangle_\Gamma$ défini plus haut. Les polynômes $\phi_n(z)$ considérés ici sont définis sur le disque unité $|z| \leq 1$, le produit scalaire étant toutefois calculé sur le cercle unité à l'aide de $\langle f|g \rangle_\Gamma$. La suite $\{\phi_n(z)\}_{n \in \mathbb{N}}$ est une suite de polynômes orthogonaux associée à la mesure Γ si $\langle \phi_n | \phi_m \rangle_\Gamma = \kappa_n \delta_{nm}$. Enfin, les $\phi_n(z)$ sont considérés ici dans leur forme monique, à savoir que $\phi_n(z) = z^n + \dots$

On considère maintenant l'opérateur anti-unitaire $*$ défini par $\phi_n^*(z) = z^n \overline{\phi_n(1/\bar{z})}$. Donc $\phi_n^*(0) = 1$ (les polynômes considérés sont moniques). La suite $\{\phi_n(z)\}_{n \in \mathbb{N}}$ de polynômes orthogonaux satisfait alors la récursion de Szegő [26, p.56]

$$\begin{pmatrix} \phi_{n+1} \\ \phi_{n+1}^* \end{pmatrix} = \begin{pmatrix} z & -\bar{\alpha}_n \\ -\alpha_n z & 1 \end{pmatrix} \begin{pmatrix} \phi_n \\ \phi_n^* \end{pmatrix}$$

$$\|\phi_{n+1}\|_\Gamma^2 = (1 - |\alpha_n|^2) \|\phi_n\|_\Gamma^2$$

où la suite des α_n appartient au disque unité ouvert. Cette suite constitue la suite des *coefficients de Verblunsky* de la mesure Γ . Comme $\phi_n^*(0) = 1$, on a $\alpha_n = -\overline{\phi_{n+1}(0)}$. Les coefficients de Verblunsky peuvent être déterminés en fonction des moments de la mesure, c'est-à-dire de la suite $\{c_n\}_{n \in \mathbb{Z}}$ définie par

$$c_n = \int_{-1/2}^{1/2} e^{2i\pi n\lambda} d\Gamma(\lambda)$$

Un lien fondamental entre la matrice Toeplitz $T^n = (c_{j-i})_{1 \leq i, j \leq n}$ et les coefficients α_n peut être établi *via* les déterminants $D^n(d\Gamma) = \text{Det } T^{n+1}$:

$$\alpha_n = (-1)^n \frac{D^n(e^{-2i\pi\lambda} d\Gamma)}{D^n(d\Gamma)}$$

([26, p.65]).

Théorème de Verblunsky vs problème des moments. Le problème des moments pose la question de savoir si une suite de nombres c_n peuvent être considérés comme les moments d'une mesure [1]. En traitement du signal, cette question revient à savoir si une telle suite de nombres peut être considérée comme une fonction de corrélation. Le théorème de Carathéodory-Toeplitz stipule que ces nombres constituent la suite des moments d'une mesure sur le cercle unité si et seulement si les déterminants D^n associés sont positifs pour tout n . Le théorème de Verblunsky donne la réponse au problème, non plus pour les coefficients de corrélation c_n mais pour les coefficients de corrélations partielles α_n . Ce théorème stipule qu'à toute suite $\{\alpha_n\}_{n \in \mathbb{N}}$ de nombres appartenant au disque unité est associée une unique mesure sur le cercle unité (et réciproquement).

On a alors le théorème de Szegő

$$\sigma_\infty^2 = \prod_{j=0}^{\infty} (1 - |\alpha_j|^2) = \exp \int_{-1/2}^{1/2} \log \gamma(\lambda) d\lambda$$

$$\sum_{j \in \mathbb{N}} |\alpha_j|^2 < +\infty \iff \int_{-1/2}^{1/2} \log \gamma(\lambda) d\lambda > -\infty$$

où $\gamma(\lambda)$ est la partie absolument continue par rapport à $d\lambda$ de la mesure associée à $\{\alpha_n\}_{n \in \mathbb{N}}$. Le deuxième point de ce théorème est intéressant quand on considère des cas qui le violent. Si par exemple $\int_{-1/2}^{1/2} \log \gamma(\lambda) d\lambda$ diverge, alors $\sigma_\infty = 0$ et la prédiction linéaire est singulière : le présent du processus aléatoire est entièrement déterminé par son passé.

Le théorème de Baxter est aussi d'intérêt : la série des coefficients de Verblunski est sommable si et seulement si la série des moments de la mesure associée le sont et $\gamma(\lambda) > 0$. Par exemple, les coefficients de corrélation partielles d'un modèle à longue dépendance (FARIMA) décroissent en $1/n$ [6], ce qui en appliquant ce théorème montre que la série des corrélations n'est pas non plus sommable.

Problème variationnel et fonction de Christoffel. La fonction de Christoffel associée au noyau (fonction symétrique définie positive) $k(x, y)$ qui génère un espace de Hilbert à noyau reproduisant (rkHs) $\mathcal{H}$ est définie par

$$\Lambda(x) = \inf_{f \in \mathcal{H}} (\|f\|_{\mathcal{H}}^2 / f(x) = 1)$$

dont on montre facilement qu'elle égale à $k(x, x)$.

Considérons l'ensemble $\mathbb{C}_p[z]$ des polynômes complexes de la variable complexe de degré inférieur à p . La forme bilinéaire

$$\begin{aligned} \langle \sum_i \alpha_i z^i | \sum_j \beta_j z^j \rangle &= \sum_{i,j} \alpha_i \overline{\beta_j} \oint_{\partial \mathbb{D}} z^i z^{-j} \gamma(z) \frac{dz}{z} \\ &= \sum_{i,j} \alpha_i \overline{\beta_j} \underbrace{\int_{-1/2}^{1/2} e^{2i\pi(i-j)\lambda} d\gamma(\lambda)}_{c_{i-j}} \end{aligned}$$

satisfait les axiomes d'un produit hermitien. Elle est définie positive puisque les c_i étant les coefficients de corrélation (ou les moments) de la densité γ , l'expression précédente est positive ou nulle pour toutes suites α, β . $\mathbb{C}_p[z]$ peut donc être vu comme un rkHs avec ce produit hermitien. Son noyau peut être écrit comme

$$k_p(z, w) = \sum_{i=0}^p \varphi_i(z) \overline{\varphi_i(w)}$$

et la fonction de Christoffel associée en 0 est par suite

$$\Lambda_p(0) = \inf_{p \in \mathbb{C}_p[z]} (\|p\|^2 / p(0) = 1)$$

On peut en particulier écrire en imposant $z \in \partial \mathbb{D}$ (soit $z = \exp(2i\pi\lambda)$) que

$$\Lambda_p(0) = \inf_{b^p \in \mathbb{C}^p} (\|1 + \sum_j b_j e^{2i\pi j\lambda}\|^2)$$

8 Lien entre les OPUC et la prédiction linéaire

L'isomorphisme de Kolmogorov. Le Lemme 4 de [13] établit l'isomorphisme K entre l'espace engendré par la suite $\{x_t\}_{t \in \mathbb{Z}}$ et l'espace $L^2([-1/2; 1/2], \Gamma_x)$ des fonctions de carré intégrable sur $[-1/2; 1/2]$ contre la mesure spectrale de x_t , explicitement par

$$\begin{aligned} K : \mathcal{H}_x &\longrightarrow L^2(\Gamma_x) \\ x_t &\longmapsto \exp(2i\pi t\lambda) \end{aligned}$$

par lequel $\langle x|y \rangle_{\mathcal{H}} = \langle K(x)|K(y) \rangle_{\Gamma_x}, \forall x, y \in \mathcal{H}_x$. Ce résultat n'est rien d'autre que le fait évident aujourd'hui que fonction de corrélation et densité spectrale de puissance sont transformées de Fourier l'une de l'autre. Ce résultat fondamental met en regard une série stationnaire d'un espace de Hilbert et les fonctions de carré sommable contre une mesure (dépendante de la série) sur le cercle unité.

Bouclons la boucle. Soit x_t une séquence stationnaire, de densité spectrale de puissance $\gamma(\lambda)$. Appliquons l'isomorphisme de Kolmogorov au problème (2). On obtient alors

$$\begin{aligned}\Lambda_p(0) &= \inf_{b^p \in \mathbb{C}^p} (\|1 + \sum_j b_j^p e^{2i\pi j\lambda}\|^2) \\ &= \inf_{a^p} \|x_t - \sum_{i=1}^p a_i^p x_{t-i}\|_{\mathcal{H}}^2\end{aligned}$$

Autrement dit, calculer la fonction de Christoffel associée à la mesure $\gamma(\lambda)d\lambda$ est équivalent à calculer l'erreur quadratique moyenne de prédiction à un pas pour une série stationnaire de densité spectrale de puissance $\gamma(\lambda)$. On montre en effet [26, p. 118] que

$$\Lambda_p(0) = \prod_{j=0}^{p-1} (1 - |\alpha_p|^2)$$

où $\{\alpha_p\}_p$ est la suite des coefficients de Verblunski, et par suite

$$\lim_{p \rightarrow \infty} \Lambda_p(0) = \sigma_{\infty}^2$$

Si la fonction de Christoffel est fondamentalement liée à l'erreur quadratique moyenne de prédiction, un lien étroit doit également exister pour les opérations réalisant les minimisations dans les deux programmes précédents.

En examinant de près la récursion de Szegö et l'algorithme de Levinson, on s'aperçoit assez aisément qu'il s'agit de deux interprétations de la même récursion, une implantée temporellement, l'autre de manière équivalente par l'isomorphisme dans le domaine transformé (en z ou en fréquences réduites λ).

9 Quelques conséquences diverses et variées

Approximation de Bernstein-Szegö. Cette approximation peut être vue comme le problème d'identification d'un processus stochastique par un modèle AR. Soit une mesure μ sur le cercle unité, $\{\alpha_n\}_{n \in \mathbb{N}}$ ses coefficients de Verblunski et $\{\varphi_n\}_{n \in \mathbb{N}} = \{\phi_n / \|\phi_n\|\}_{n \in \mathbb{N}}$ la suite de ses polynômes *orthonormaux*. Alors pour tout n , $|\varphi_n(\lambda)|^{-2}$ est une densité de probabilité (une densité spectrale de puissance normalisée), la mesure $d\mu_n = |\varphi_n(\lambda)|^{-2} d\lambda$ a pour coefficients de Verblunski $\{\alpha_j\}_{0 \leq j < n}$ et 0, $\forall j \geq n$, et μ_n converge vers μ (faiblement) quand n tend vers l'infini.

Taux d'entropie d'un processus Gaussien stationnaire. Le taux d'entropie $H(x)$ d'un processus stationnaire x de densité spectrale γ est défini par l'asymptotique de l'entropie d'un vecteur des échantillons de x , $\lim 1/nH(x_1, x_2, \dots, x_n)$. Appliquée à un processus gaussien de coefficients de corrélation c_k , on obtient aisément

$$H(x) = \lim_{n \rightarrow +\infty} \frac{1}{n} \log((2\pi e)^{n/2} \sqrt{D_n})$$

Le résultat de Szegö de 1915 concerne l'asymptotique des déterminants de matrices Toeplitz. Il montre que $\lim D_{n+1}/D_n = \sigma_{\infty}^2 = \lim D_n^{1/n}$, qui permet donc de montrer que $H(x) = \log((2\pi e)^{n/2} \int \log \gamma(\lambda) d\lambda)$.

10 Filtre de Kalman

Le développement du filtrage optimal utilisant une représentation d'état markovienne conduit à une formulation récursive naturelle. Présentation rapide du filtre, lien avec le filtre de Wiener dans le cas invariant, factorisation spectrale ???

11 Extension multivariée.

L'extension multivariée s'intéresse à généraliser les liens entre le prédicteur optimal d'un signal multivarié x_t et la théorie des polynômes orthogonaux multivariés sur le cercle unité, ou MOPUC pour Multivariate Orthogonal Polynomial on the Unit Circle. Ces polynômes sont des polynômes de la variable complexe à coefficients matriciels à valeurs complexes, qui sont des MOPUC lorsque la variable complexe z s'écrit $e^{i\theta}$.

Pour généraliser les résultats scalaires rappelés ici, il est nécessaire de travailler avec des matrices de fonctions complexes de la variable complexe, de définir des espaces de travail adéquats, des propriétés métriques adéquates, ... La section 13 réunit le matériel nécessaire.

Récursion de Szegő multivariée. Soit γ une mesure matricielle sur $\partial\mathbb{D}$. En appliquant la procédure de Gram-Schmidt à $I, zI, z^2I, \dots$, on définit deux suites de polynômes orthogonaux moniques $\Phi_n^{R,L} = z^n I + \text{l.o.t.}$ qui vérifient $\ll z^k | \Phi_n^{R,L} \gg_{R,L} = 0, \forall k = 0, \dots, n-1$. Les versions normalisées $\varphi_n^{R,L}$ vérifient $\varphi_0^{R,L} = I, \varphi_n^L = \kappa_n^L \Phi_n^L$ et $\varphi_n^R = \Phi_n^R \kappa_n^R$, les $\kappa_n^{R,L}$ étant choisis de sorte que $\ll \varphi_n^{R,L} | \varphi_m^{R,L} z \gg_{R,L} = \delta_{n,m} I$

Pour le polynôme $P_n(z)$ de degré n , on définit le polynôme renversé $P_n^*(z)$ par

$$P_n^*(z) = z^n P_n\left(\frac{1}{z}\right)^\dagger$$

Si $P_n(z)$ de degré n est orthogonal à gauche à tous les monômes $zI, \dots, z^n I$ alors il est proportionnel au renversé du polynôme monique orthogonal droite, $P_n = c(\Phi_n^R)^*$. On montre en effet que $\forall j = 1, \dots, n, 0 = \ll P_n | z^j I \gg_L = \ll z^{n-j} I | P_n^* \gg_R$.

Alors, la récursion de Szegő suit :

$$\begin{cases} z\varphi_n^L - \rho_n^L \varphi_{n+1}^L &= \alpha_n^\dagger \varphi_n^{R,*} \\ z\varphi_n^R - \varphi_{n+1}^R \rho_n^R &= \varphi_n^{L,*} \alpha_n^\dagger \end{cases}$$

où $\rho_n^L = \kappa_n^L (\kappa_{n+1}^L)^{-1}$ et $\rho_n^R = (\kappa_{n+1}^R)^{-1} \kappa_n^R$

avec $\rho_n^L = (I - \alpha_n^\dagger \alpha_n)^{1/2}$ et $\rho_n^R = (I - \alpha_n \alpha_n^\dagger)^{1/2}$

La preuve se fait en deux étapes. On note que $z\varphi_n^L$ a κ_n^L pour coefficient d'ordre $n+1$. $\rho_n^L \varphi_{n+1}^L$ a quant à lui $\rho_n^L \kappa_{n+1}^L$ pour coefficient d'ordre $n+1$, soit également κ_n^L . Donc $z\varphi_n^L - \rho_n^L \varphi_{n+1}^L$ est de degré au plus n . On montre aisément que ce polynôme est orthogonal aux $zI, \dots, z^n I$, et est donc proportionnel à $\varphi_n^{R,*}$. Soit α_n^R le coefficient de proportionnalité. De même $z\varphi_n^R - \varphi_{n+1}^R \rho_n^R$ est proportionnel à $\varphi_n^{L,*} \alpha_n^\dagger$ de coefficient α_n^L . Dans un deuxième temps, on montre que $\alpha_n^R = \alpha_n$ (voir l'appendice).

Les matrices α_n sont les coefficients de Verblunski de la mesure matricielle γ . Ils vérifient $\|\alpha_n\| < 1$.

Algorithme de Levinson multivarié. Wiggins&Robinson étendent l'algorithme de Levinson en 1965 [35]. Soit y_t une série stationnaire multivariée que l'on souhaite prédire à un pas.

On suppose connaître les prédictors directs et rétrogrades d'ordre n et $(n+1)$ qui vérifient

$$\begin{bmatrix} I & A_1^n & A_2^n & \dots & A_n^n & 0 \\ I & A_1^{n+1} & A_2^{n+1} & \dots & A_n^{n+1} & A_{n+1}^{n+1} \\ 0 & B_n^n & B_{n-1}^n & \dots & B_1^n & I \\ B_{n+1}^{n+1} & B_n^{n+1} & B_{n-1}^{n+1} & \dots & B_1^{n+1} & I \end{bmatrix} \begin{bmatrix} y_{t+n} \\ y_{t+n-1} \\ \vdots \\ y_t \\ y_{t-1} \end{bmatrix} = \begin{bmatrix} w_n^f \\ w_{n+1}^f \\ w_n^b \\ w_{n+1}^b \end{bmatrix}$$

Le vecteur de données est de dimension $d(n+2)$. Ses extrémités sont les données à prédire de manière rétrograde ou directe à partir des n vecteurs de la partie centrale. Les innovations w portent le superscript f pour direct (forward) ou b pour rétrograde (backward), et sont indicées par l'ordre du prédictor, non le temps. Soit $\mathbb{R}_N$ de taille $nd \times nd$ la matrice de covariance du vecteur y de taille nd qui concatène n observations y_{t-i} , chacune de dimension d . $\mathbb{R}_N$ est une matrice bloc, le bloc (i, j) étant $R_{i-j} = E[y_i y_j^\dagger]$.

En multipliant à droite l'équation précédente par le transposé hermitien du vecteur de données, puis en prenant l'espérance mathématique, on obtient

$$\begin{bmatrix} I & A_1^n & A_2^n & \dots & A_n^n & 0 \\ I & A_1^{n+1} & A_2^{n+1} & \dots & A_n^{n+1} & A_{n+1}^{n+1} \\ 0 & B_n^n & B_{n-1}^n & \dots & B_1^n & I \\ B_{n+1}^{n+1} & B_n^{n+1} & B_{n-1}^{n+1} & \dots & B_1^{n+1} & I \end{bmatrix} \mathbb{R}_{N+2} = \begin{bmatrix} \varepsilon_n^f & 0 & \dots & 0 & \alpha_n^f \\ \varepsilon_{n+1}^f & 0 & \dots & 0 & 0 \\ \alpha_n^b & 0 & \dots & 0 & \varepsilon_n^b \\ 0 & 0 & \dots & 0 & \varepsilon_{n+1}^b \end{bmatrix}$$

Ce résultat est dû au fait que l'innovation directe w^f (resp. w_n^b) est orthogonale à $y_{t+n-1}, \dots, y_t$ mais n'a aucune raison de l'être de y_{t-1} (resp. y_{t-n}). La notation $\varepsilon_n^{f,b}$ représente donc l'erreur quadratique de prédiction minimale à l'ordre n . Les α sont expliquées plus bas.

On montre maintenant que $\alpha_n^f = E[w_n^f y_{t-1}^\dagger]$ est la transposée hermitienne de $\alpha_n^b = E[w_n^b y_{t+n}^\dagger]$. $\alpha_n^f = E[\sum_{i=0}^n A_i^n y_{t+N-i} y_{t-1}^\dagger] = \sum_{i=0}^n A_i^n R_{n+1-i}$ avec la convention $A_0^n = I$. De plus $[IA_1^n \dots A_n^n][y_{t+n} \dots y_t]^\top \perp [y_{t+N-1} \dots y_t]$, et donc

$$[IA_1^n \dots A_n^n] \begin{bmatrix} y_{t+n} \\ \vdots \\ y_t \end{bmatrix} \perp \begin{bmatrix} y_{t+n-1} \\ \vdots \\ y_{t-1} \end{bmatrix}$$

$$[IA_1^n \dots A_n^n] \begin{bmatrix} R_1 & \dots & R_N \\ \mathbb{R}_N \end{bmatrix} = 0 \iff [A_1^n \dots A_n^n] = -[R_1 \dots R_n] \mathbb{R}_n^{-1}$$

qui sont les équations de Yule-Walker. De même $[B_n^n \dots B_1^n] = -[R_{-v} \dots R_{-1}] \mathbb{R}_n^{-1}$ et donc

$$\alpha_n^f = R_{n+1} - [R_1 \dots R_n] \mathbb{R}_n^{-1} \begin{bmatrix} R_n \\ \vdots \\ R_1 \end{bmatrix}$$

$$\alpha_n^b = R_{-n-1} - [R_{-n} \dots R_{-1}] \mathbb{R}_n^{-1} \begin{bmatrix} R_{-1} \\ \vdots \\ R_{-n} \end{bmatrix}$$

qui sont transposées hermitiennes l'une de l'autre puisque $R_k^\dagger = R_{-k}$. De plus $\alpha_n = \alpha_n^f = E[w_n^f y_{t-1}^\dagger] = E[w_n^f (w_n^b)^\dagger]$ est la covariance résiduelle entre y_{t+n} et y_{t-1} quand la contribution linéaire des échantillons centraux a été enlevée : en d'autres termes α_n^f et α_n^b sont les covariances partielle directes et rétrogrades !

Ensuite, à le grand système moyen peut se réécrire à l'aide de deux matrices K_A and K_B telles que

$$\begin{aligned} (IA_1^n \dots A_n^n \mathbf{0}) + K_A(\mathbf{0}B_n^n \dots B_1^n I) &= [IA_1^{n+1} \dots A_{n+1}^{n+1}] \\ (\mathbf{0}B_n^n \dots B_1^n I) + K_B(IA_1^n \dots A_n^n \mathbf{0}) &= [B_{n+1}^{n+1} \dots B_1^{n+1} I] \end{aligned}$$

à condition que

$$\begin{aligned} \alpha_n^f + K_A \varepsilon_n^b &= 0 \\ \varepsilon_n^f + K_A \alpha_n^b &= \varepsilon_{n+1}^f \\ \alpha_n^b + K_B \varepsilon_n^f &= 0 \\ \varepsilon_n^b + K_B \alpha_n^f &= \varepsilon_{n+1}^b \end{aligned}$$

conduisant aux récursions

$$\begin{aligned} (IA_1^{n+1} \dots A_{n+1}^{n+1}) &= (IA_1^n \dots A_n^n \mathbf{0}) - \alpha_n(\varepsilon_n^b)^{-1}(\mathbf{0}B_n^n \dots B_1^n I) \\ (B_{n+1}^{n+1} \dots B_1^{n+1} I) &= (\mathbf{0}B_n^n \dots B_1^n I) - \alpha_n^\dagger(\varepsilon_n^f)^{-1}(IA_1^n \dots A_n^n \mathbf{0}) \\ \varepsilon_{n+1}^f &= \varepsilon_n^f - \alpha_n(\varepsilon_n^b)^{-1}\alpha_n^\dagger \\ \varepsilon_{n+1}^b &= \varepsilon_n^b - \alpha_n^\dagger(\varepsilon_n^f)^{-1}\alpha_n \end{aligned}$$

Revenons aux polynômes. Considérons la définition suivante de la transformée en z ,

$$y(z) = \sum_t y_t z^{-t}$$

de sorte que $z^n y(z)$ est la transformée de y_{t+n} .

Soit $A^n(z) = z^n I + A_1^n z^{n-1} + \dots + A_{n-1}^n z + A_n^n$. Alors $A^n(z)y(z) = w_n^f(z)$. De même, $B^n(z) = z^n I + B_1^n z^{n-1} + \dots + B_{n-1}^n z + B_n^n$.

La mise à jour des A_i^n s peut alors s'écrire

$$\begin{aligned} A^{n+1}(z) &= zA^n(z) - \alpha_n(\varepsilon_n^b)^{-1}z^n B^n(1/z) \\ B^{n+1}(z) &= zB^n(z) - \alpha_n^\dagger(\varepsilon_n^f)^{-1}z^n A^n(1/z) \end{aligned}$$

Toutefois, pour faire le lien avec les MOPUC, nous utilisons la transposée hermitienne pour la définition de $B(z)$, $B^n(z) = z^n I + B_1^{n\dagger} z^{n-1} + \dots + B_{n-1}^{n\dagger} z + B_n^{n\dagger}$. La mise à jour s'écrit donc

$$\begin{aligned} A^{n+1}(z) &= zA^n(z) - \alpha_n(\varepsilon_n^b)^{-1}z^n B^n(1/\bar{z})^\dagger \\ B^{n+1}(z) &= zB^n(z) - z^n A^n(1/\bar{z})^\dagger(\varepsilon_n^f)^{-1}\alpha_n \end{aligned}$$

On peut maintenant présenter la version normalisée, en considérant les corrélations partielles plutôt que les covariances partielles. Soit $\tilde{\alpha}_n = (\varepsilon_n^f)^{-1/2}\alpha_n(\varepsilon_n^b)^{-1/2}$. Define also $\tilde{A}^n(z) = (\varepsilon_n^f)^{-1/2}A^n(z)$ and $\tilde{B}^n(z) = B^n(z)(\varepsilon_n^b)^{-1/2}$ the normalized polynomials. Then the update write

$$\begin{aligned} \tilde{A}^{n+1}(z) &= \sigma_n^f(z\tilde{A}^n(z) - \tilde{\alpha}_n z^n \tilde{B}^n(1/\bar{z})^\dagger) \\ \tilde{B}^{n+1}(z) &= (z\tilde{B}^n(z) - z^n \tilde{A}^n(1/\bar{z})^\dagger \tilde{\alpha}_n) \sigma_n^b \end{aligned}$$

où $\sigma_n^f = (\varepsilon_{n+1}^f)^{-1/2}(\varepsilon_n^f)^{1/2}$ et $\sigma_n^b = (\varepsilon_n^b)^{1/2}(\varepsilon_{n+1}^b)^{-1/2}$.

En utilisant la récursion pour les erreurs on montre $\sigma_n^f = (I - \tilde{\alpha}_n \tilde{\alpha}_n^\dagger)^{-1/2}$ and $\sigma_n^b = (I - \tilde{\alpha}_n^\dagger \tilde{\alpha}_n)^{-1/2}$.

C'est précisément la récursion de Szegö pour MOPUC normalisés !

La séquence de polynôme $\tilde{A}^n(z)$ est donc la séquence des polynômes orthogonaux normalisés pour $\ll F | G \gg_R$ quand la mesure considérée est la matrice spectrale du processus.

Le problème du renversement du temps. Une différence majeure entre les cas scalaire et multivarié apparaît dans la récursion de Levinson et de Szegö : il faut deux séquences distinctes dans le cas multivarié quand il n'en faut qu'une en scalaire !

Le cas scalaire est singulier puisque la prédiction linéaire ne mobilisant que des statistiques d'ordre 2, et que stationarité d'ordre 2 impliquant la réversibilité d'ordre 2, les récursions directes et rétrogrades sont naturellement égales. Ce n'est plus vrai en multivarié.

Il est nécessaire de discuter un peu plus la réversibilité en temps des processus stochastiques. Assez peu de littérature est dédiée à cette question. On pourra lire par exemple [33, 20, 18, 15] pour des références assez anciennes et [30, 7] pour quelques références plus récentes. Notons que cette notion est très utilisée dans les techniques les plus modernes de génération, puisque les techniques parmi les plus performantes aujourd'hui (2025) utilise des diffusions réversibles en temps.

12 Prédiction et causalité (de Wiener-Granger)

Quelques repères historiques :

1915 : Szegö résoud une conjecture proposé par Pólya sur le comportement asymptotique des déterminants de matrice Toeplitz. En langage de ce papier : $\sigma_\infty^2 = \lim D_n^{1/n}$.

1927 : Yule introduit l'auto régression pour modéliser des séries d'apparence périodique ; applique à la série des taches solaires.

1931 : Walker montre que l'autorégression introduite par Yule est satisfaite également par la fonction de corrélation : équation appelée aujourd'hui Yule-Walker. Méthode de Wiener-Hopf pour résoudre l'équation intégrale du même nom.

1931-34 : Kolmogorov formalise la théorie des probabilités et Khintchine celle des processus stochastiques.

Sir Walker généralise le papier de Yule dans un travail où apparaît explicitement l'équation de Yule-Walker.

1935-36 : Verblunski développe le problème des moments dans le monde des corrélations partielles (évidemment pas dans ces termes)

1938 : Wold défend sa thèse, publiée sous forme de livre [36].

1939 : dans un papier aux CRAS, Kolmogorov donne l'erreur quadratique moyenne asymptotique pour l'interpolation et la prédiction de signaux aléatoires à temps discrets stationnaires.

1941 : les preuves des résultats de 1939 sont données à travers deux papiers fondamentaux.

1942 : Wiener travaille pour l'armée américaine à des techniques de prédiction pour l'aide au guidage de systèmes de tir.

1947 : Levinson apporte une solution récursive au problème de la prédiction de Wiener en temps discret (redécouverte en 1960 par Durbin).

Références

- [1] N.I. Akhiezer. *The classical moment problem and some related questions in analysis*. Oliver&Boyd, 1965.
- [2] D. Alter. A group or correlation periodogram, with application to the rainfall of the british isles. *Mont. Weath. Rev.*, 55(6) :263–266, 1927.
- [3] P. O. Amblard. Petite histoire de $\sigma_\infty^2 = \exp \int \log \gamma(\lambda) d\lambda$ et de la prédiction à un pas. In *GRETSI*, Strasbourg, 2025.
- [4] N. H. Bingham. Szegö theorem and its probabilistic descendant. *Probability Surveys*, 9 :287–324, 2012.
- [5] A. Blanc-Lapierre and B. Picinbono. *Signaux aléatoires*. Masson, Paris, 1983.

- [6] P. J. Brockwell and R. A. Davis. *Time Series : Theory and Methods*. Springer, 1991.
- [7] K. S. Chan, L.-H. Ho, and H. Tong. A note on time-reversibility of multivariate linear processes. *Biometrika*, 93(1) :221–227, 2006.
- [8] D. Damanik, A. Pushnitski, and B. Simon. The analytic theory of matrix orthogonal polynomials. *Surveys in Approximation Theory (SAT)[electronic only]*, 4 :1–85, 2008.
- [9] R. M. Gray. Toeplitz and circulant matrices : A review. *FnT in Communications and Information Theory* :, 2(3) :155–239, 2006.
- [10] T. Kailath. A view of three decade of linear filtering theory. *IEEE Trans. Info. Th.*, 20(2) :146–181, 1974.
- [11] A. Khintchine. Sulle successioni stazionarie di eventi. *Giorn. Ist. Ital. Attuari*, 3(3) :267–272, 1932.
- [12] A. Khintchine. Korrelationstheorie der stationären stochastischen prozesse. *Mathematische Annalen*, vol. 109, no 1, 1934, p. 604–615, 109(1) :604–615, 1934.
- [13] A. N. Kolmogorov. Stationary sequences in hilbert spaces. *Byull. Moskow. Gos. univ. Mat. (reproduced in Selected works of A. N., vol ii, A. N. Shirayev ed., Springer 1992)*, 2(6) :1–40, 1941.
- [14] J. B. Lasserre, E. Pauwells, and M. Putinar. *The Christoffel-Darboux kernel for Data Analysis*. Cambridge University Press, 2022.
- [15] A. J. Lawrance. Directionality and reversibility in time series. *International Statistical Review*, 59(1) :67–79, 1991.
- [16] N. Nikolski. *Hardy spaces*. Cambridge University Press, 2019.
- [17] N. Nikolski. *Toeplitz matrices and operators*. Cambridge University Press, 2020.
- [18] H. Osawa. Reversibility of first-order autoregressive processes. *Stoch. Proc. and Appl.*, 28 :61–69, 1988.
- [19] B. Picinbono. *Random signals and systems*. Prentice Hall, 1993.
- [20] Y. Pommeau. Symétrie des fluctuations dans le renversement du temps. *J. Phys. France*, 43(6) :859–867, 1982.
- [21] Lord Rayleigh. On the resultant of a large number of vibrations of the same pitch and of arbitrary phase. *Phil. Mag. and J. of Sc.*, 10(60) :73–78, 1880.
- [22] A. Schuster. On lunar and solar periodicities of earthquakes. *Proc. Roy. Soc. London*, 61 :455–465, 1897.
- [23] A. Schuster. On the investigation of hidden periodicities with application to a supposed 26 day period of meteorological phenomena. *Terr. Magn.*, 3(1) :13–41, 1898.
- [24] A. Schuster. The periodogram of magnetic declination as obtained from the records of the greenwich observatory during the years 1871–1895. *Trans. Cambridge Phil. Soc.*, 18 :107–135, 1900.
- [25] A. Schuster. On the periodicities of sunspots. *Phil. Trans. Roy. Soc. A*, 206 :69–100, 1906.
- [26] B. Simon. *Orthogonal polynomials on the unit circle . Part I : Classical theory*. AMS, colloquium publications, 2004.
- [27] B. Simon. *Orthogonal polynomials on the unit circle . Part II : Spectral theory*. AMS, colloquium publications, 2004.
- [28] B. Simon. *Szegő's theorem and its descendants. Spectral theory for L^2 perturbations od orthogonal polynomials*. Princeton University Press, 2011.
- [29] E. Slutsky. Sur l’extension de la théorie de periodogrammes aux suites de quantités dépendantes. *CRAS, Paris*, 189 :722–725, 1929, séance de 4 novembre.
- [30] H. Tong and Z. Zhang. On time-reversibility of multivariate linear processes. *Statistica Sinica*, 15(2) :495–504, 2005.
- [31] Sir G. Walker. On periodicity. *Q. J. R. Met. Soc.*, 51 :337–346, 1925.
- [32] Sir G. Walker. On periodicities in series of related terms. *Proc. Roy. Soc. London, A*, 131(818) :518–532, 1931.
- [33] G. Weiss. Time-reversibility of linear stochastic processes. *J. Applied Probability*, 12(4) :831–836, 1975.
- [34] N. Wiener. Generalized harmonic analysis. *Acta Mathematica*, 55 :117–258, 1930.

- [35] R. A. Wiggins and E. A. Robinson. Recursive solution to the multichannel filtering problem. *J. Geophys. Res.*, 1970(8) :1885–1891, 1965.
- [36] H. Wold. *A study in the analysis of stationary time series*. Almqvist&Wiksell Boktryckeri-A.-B., Uppsala, 1938.
- [37] G. U. Yule. On the time-correlation problem with especial reference to the variate-difference correlation method. *J. Royal. Stat. Soc.*, 83 :497–526, 1921.
- [38] G. U. Yule. Why do we sometimes get nonsense-correlations between times series ? a study in sampling and the nature of time series. *J. Royal. Stat. Soc.*, 89 :1–64, 1926.
- [39] G. U. Yule. On a method of investigating periodicities in disturbed series, with special reference to wolfer's sunspot numbers. *Phis. Trans. Roy. Soc., A*, 226 :267–298, 1927.

13 Appendice : MOPUC.

Cette appendice contient l'essentiel des développements nécessaire pour comprendre les MOPUC. Elle reprend essentiellement des présentations faites dans [8].

Les matrices considérées sont des éléments de $\mathbb{C}^{d \times d}$. Soit $\mathcal{P}$ l'ensemble des polynômes de la variable $z \in \mathbb{C}$ à coefficients dans $\mathbb{C}^{d \times d}$, et $\mathcal{P}_n$ cet ensemble restreint aux degrés inférieurs ou égaux à n . Ces ensembles sont des $\mathbb{C}^{d \times d}$ -modules à droite ou à gauche (équivalent des espaces vectoriels sur un corps, mais ici sur l'anneau non commutatif $(\mathbb{C}^{d \times d}, +, \cdot)$). Une mesure matricielle sur $\mathbb{R}$ ou $\mathbb{C}$ ou un de leurs sous-ensembles est une mesure qui affecte à un borélien une matrice définie-positive, cette affectation étant additive (la mesure de l'union dénombrable de boréliens est la somme des mesures). Une mesure μ normalisée est telle que $\mu(\mathbb{C}) = \mathbf{I}$, l'identité. La mesure trace est définie par $\mu_t(\cdot) = \text{Tr}(\mu(\cdot))$ de sorte que $\mu_t(\mathbb{C}) = d$. Il existe une matrice définie-positive d'éléments $M_{i,j}(z) = d\mu_{i,j}(z)/d\mu_t(z)$, de trace unité. Pour toutes fonctions à valeurs dans $\mathbb{C}^{d \times d}$ on définit

$$\ll \mathbf{F} | \mathbf{G} \gg_R = \int \mathbf{F}(z)^\dagger M(z) \mathbf{G}(z) d\mu_t(z) \text{ et } \ll \mathbf{F} | \mathbf{G} \gg_L = \int \mathbf{G}(z) M(z) \mathbf{F}(z)^\dagger d\mu_t(z)$$

Ces applications ne définissent par un produit scalaire, mais conduisent à un produit scalaire et une norme en prenant la trace : $\langle \mathbf{F} | \mathbf{G} \rangle_{R,L} = \text{Tr} \ll \mathbf{F} | \mathbf{G} \gg_{R,L}$ et $\|\mathbf{F}\|_{R,L}^2 = \text{Tr} \ll \mathbf{F} | \mathbf{F} \gg_{R,L}$.

L'espace des fonctions à valeurs matricielles pour lequel les intégrales ci-dessus existent ($\int \text{Tr}(\mathbf{F}^\dagger(z) \mathbf{F}(z)) d\mu_t(z) < +\infty$ est suffisant) est un espace de Hilbert pour le produit scalaire $\langle \mathbf{F} | \mathbf{G} \rangle_{R,L}$ (completion quotientée par l'ensemble des fonctions de norme nulle).

Un ensemble $(\varphi_{i,j})_{i,j \in \mathcal{I}}$ est orthonormal si $\ll \varphi_i | \varphi_j \gg_R = \delta_{i,j} \mathbf{I}$ ($\mathcal{I}$ peut être fini ou dénombrable). Soit $\mathcal{H}_\varphi$ le sous-espace de $\mathcal{H}$ engendré par $(\varphi_{i,j})_{i,j \in \mathcal{I}}$. Alors $\pi_\varphi(\mathbf{F}) = \sum_{i \in \mathcal{I}} \varphi_i \ll \varphi_i | \mathbf{F} \gg_R$ est le projecteur orthogonal de $\mathcal{H}$ sur $\mathcal{H}_\varphi$ pour le produit scalaire $\langle \mathbf{F} | \mathbf{G} \rangle_R$.

Soit γ une mesure matricielle sur $\partial\mathbb{D}$. En appliquant la procédure de Gram-Schmidt à $\mathbf{I}, z\mathbf{I}, z^2\mathbf{I}, \dots$, on définit deux suites de polynômes orthogonaux moniques $\Phi_n^{R,L} = z^n \mathbf{I} + \text{l.o.t.}$ qui vérifient $\ll z^k | \Phi_n^{R,L} \gg_{R,L} = \mathbf{0}, \forall k = 0, \dots, n-1$. Notons que le produit scalaire est calculé sur $\partial\mathbb{D}$, soit

$$\langle \mathbf{F} | \mathbf{G} \rangle_R = \text{Tr} \left(\int_{-1/2}^{1/2} \mathbf{F}(\lambda)^\dagger d\mu(\lambda) \mathbf{G}(\lambda) \right) \text{ et } \langle \mathbf{F} | \mathbf{G} \rangle_L = \text{Tr} \left(\int_{-1/2}^{1/2} \mathbf{G}(\lambda) d\mu(\lambda) \mathbf{F}(\lambda)^\dagger \right)$$

où l'on fait l'abus usuel de notation $\mathbf{F}(e^{2i\pi\lambda}) \leftrightarrow \mathbf{F}(\lambda)$, et où les $\ll \mathbf{F} | \mathbf{G} \gg_{R,L}$ sont implicitement définies par les intégrales dans les Tr.

Pour le polynôme de degré n $P_n(z)$, on définit le polynôme renversé $P_n^*(z)$ par

$$P_n^*(z) = z^n P_n\left(\frac{1}{z}\right)^\dagger$$

Les propriétés suivantes se vérifient directement :

$$\begin{aligned} \ll \mathbf{F} | \mathbf{G} \gg_{R,L} &= \ll \mathbf{G} | \mathbf{F} \gg_{R,L}^\dagger \\ (P_n^*)^* &= P_n \\ \ll \mathbf{F}^* | \mathbf{G}^* \gg_{R,L} &= \ll \mathbf{F} | \mathbf{G} \gg_{L,R}^\dagger \\ (\alpha P_n \beta)^* &= \beta^\dagger P_n^* \alpha^\dagger \end{aligned}$$